



INTELIGÊNCIA ARTIFICIAL APLICADA

Instituto NTA

Engenharia de IA Aplicada

Programa completo da série pública: um agente de IA construído do zero ao deploy, em Python, com código aberto. Agentes, RAG, MCP, avaliação e produção.

SÉRIE ABERTA · AULA POR AULA · CÓDIGO NO REPOSITÓRIO

Para desenvolvedores Python de nível intermediário. Sem framework antes da hora. Sem matemática de rede neural.

Prof. Thiago Azeredo Rodrigues

ENGENHEIRO DE IA · INSTITUTO NTA

Programa da série · 2026 · Acompanhe as publicações no LinkedIn

Como esta série funciona

Esta é uma formação aberta em engenharia de IA aplicada, publicada aula por aula no LinkedIn. Cada publicação corresponde a uma aula deste programa: o conceito, a decisão de engenharia por trás dele e o código que a implementa.

Todo o código vive num repositório público, com uma tag por aula. Isso significa que você pode entrar em qualquer ponto da série com o projeto no estado exato daquela aula, sem precisar reproduzir as anteriores. O link do repositório acompanha cada publicação.

A série está organizada em temporadas. A primeira, que começa agora, cobre a Fase 0 completa: oito aulas, duas publicações por semana. As fases seguintes serão anunciadas ao final de cada temporada.

Para quem é

Para quem já escreve Python com desenvoltura e quer migrar para engenharia de IA aplicada: construir e operar agentes e sistemas RAG de verdade, em produção. Você não precisa saber nada sobre agentes. Precisa saber ler uma stack trace, usar Git e não se assustar com um teste que quebra.

Para quem não é

Esta série não ensina a treinar modelos, não deduz equações de rede neural e não é uma introdução à programação. A única matemática presente é a estritamente necessária, na parte de RAG, sempre explicada de forma intuitiva.

O PRINCÍPIO QUE ORGANIZA TUDO

A lógica vem antes do framework. Cada padrão é ensinado primeiro em Python puro, para você ver o mecanismo funcionando, e só depois no framework, para ver o que ele resolve e a que preço. Quem só monta agente em ferramenta visual não sabe depurar quando quebra. É a forma mais barata de construir conhecimento que sobrevive à troca de stack, e nesta área a stack troca a cada dezoito meses.

O projeto: um sistema só, do primeiro tijolo ao deploy

Você não vai ver quarenta exemplos descartáveis. A série inteira constrói um único sistema que cresce em camadas: o **Núcleo de Agentes Operacionais**, um assistente multi-agente de qualificação e atendimento de leads B2B para um SaaS fictício. Ao final, é um produto que uma empresa realmente compraria, e um repositório que serve de portfólio.

Camada	O que faz	Fase
Canal	Entrada por WhatsApp Business, Slack ou web	4
Supervisor	Lê a intenção e roteia para o especialista certo	2
Especialistas	Agente de conhecimento (RAG agêntico), agente de ação (CRM, agenda, tickets) e agente de triagem	0 a 2
Ferramentas via MCP	Um servidor MCP próprio expando as integrações de forma padronizada e replicável	2

Observabilidade e avaliação	Tracing, harness de avaliação contínua, custo por sessão e guardrails	0 e 3
Deploy	FastAPI, Docker e Kubernetes	4

Práticas de 2026 do início ao fim: LangGraph com estado durável e human-in-the-loop, MCP e A2A, Langfuse para observabilidade, retrieval híbrido com reranking, FastAPI, Docker e Kubernetes.

O mapa completo

FASE 0 · TEMPORADA ATUAL · 8 AULAS

O agente em código puro, sem framework

O loop de agente construído na mão, antes de qualquer abstração. Function calling e tool use nos dois grandes providers através de uma camada agnóstica; a anatomia do loop (contexto, decisão, ação, observação); saída estruturada com Pydantic; resiliência a erro de ferramenta; e observabilidade desde o primeiro dia.

ENTREGÁVEL · Agente de ação com três ferramentas reais, agnóstico de provider, resiliente e rastreado. O primeiro tijolo do Núcleo.

FASE 1 · CERCA DE 8 AULAS

Orquestração estruturada com LangGraph

Do loop artesanal ao grafo de estado: state, nodes, edges condicionais, checkpointing e durabilidade. Human-in-the-loop como primitivo, com aprovação, interrupção e retomada. Os padrões de raciocínio ReAct, plan-and-execute e reflection, sempre comparados com custo e latência medidos.

ENTREGÁVEL · O agente da Fase 0 como grafo, com aprovação humana numa etapa sensível e estado que sobrevive a restart.

FASE 2 · CERCA DE 10 AULAS

Multi-agente, MCP e interoperabilidade

Padrões multi-agente (supervisor, handoffs, swarm) e quando cada um faz sentido. Context engineering como disciplina: as quatro estratégias de gestão da janela. Memória de agente de curto e longo prazo. MCP na prática, incluindo a construção de um MCP server próprio, e a noção de A2A. O RAG vira ferramenta que o agente decide usar.

ENTREGÁVEL · Supervisor mais dois especialistas, com um MCP server customizado expondo as integrações.

TRILHO R · CERCA DE 10 AULAS

RAG em produção, do fundamento ao estado da arte

O pipeline completo: embeddings e a matemática intuitiva da similaridade, escolha de modelo com dados, chunking por tipo de documento, busca híbrida (densa mais BM25 com fusão RRF), reranking com cross-encoder, transformações de query, bancos vetoriais e índices ANN, as variantes modernas (Self-RAG, Corrective RAG, GraphRAG) e avaliação com RAGAS sobre um golden set.

ENTREGÁVEL · Um advanced RAG medido por métrica, capaz de diagnosticar onde falha: recall, precision ou ordenação.

FASE 3 · CERCA DE 8 AULAS

Avaliação e observabilidade nível produção

Medir agente é diferente de medir RAG: trajetória, acurácia de seleção de ferramenta e task completion. LLM-as-judge com rigor e calibração contra rótulos humanos. Datasets, experiments e prompt versionado como código. Controle de custo por sessão, caching, roteamento de modelo. Guardrails de entrada e saída.

ENTREGÁVEL · Harness de avaliação e dashboard de custo rodando em CI: mudança que piora o sistema é pega antes de subir.

FASE 4 · CERCA DE 8 AULAS

Deploy e produção real

O agente como serviço: FastAPI com async, streaming e gestão de sessão. Docker e o Kubernetes que importa na prática, com secrets, health check e scaling. CI/CD com gate de qualidade: só sobe se a avaliação passar. Integração com canais reais: WhatsApp Business, Slack, webhook.

ENTREGÁVEL · O sistema multi-agente no ar, com observabilidade e avaliação contínua, atendendo num canal real.

FASE 5 · CERCA DE 6 AULAS

A blindagem do sênior

Os pontos que separam um bom engenheiro de um sênior à prova de sabatina: fluência no funcionamento do modelo (tokens, sampling, janela de contexto), fine-tuning como decisão de engenharia e não como reflexo, segurança a fundo (prompt injection, PII, red teaming do próprio sistema) e a tradução de problema de negócio em arquitetura.

ENTREGÁVEL · Repositório publicado, case study e demo gravada do Núcleo.

A temporada que começa agora: Fase 0 aula por aula

Aula	Tema	Você sai sabendo
0.1	A camada agnóstica de provider	Uma função que fala com Claude e GPT trocando uma variável, com segredos fora do código e testes sem rede
0.2	Tool use, o mecanismo cru	O ciclo de quatro etapas em que o modelo pede e o seu código executa, nos dois dialetos
0.3	O loop de agente	O while que transforma chamadas em autonomia, com as quatro condições de parada que evitam incidente com fatura
0.4	Registro de ferramentas	Um decorator que deriva o schema da própria função: adicionar ferramenta vira escrever uma função
0.5	As três ferramentas do domínio	CRM, agenda e tickets sobre SQLite, e as quatro regras de design que mudam a acurácia de seleção
0.6	Saída estruturada e resiliência	Erro de ferramenta como observação que o agente contorna, e resposta final validada com Pydantic
0.7	Observabilidade desde o berço	Cada execução rastreada em árvore, com custo em tokens e latência por passo
0.8	O primeiro tijolo	O repositório consolidado, e a fronteira exata entre o que é portátil e o que vira framework

Cada aula foi desenhada para cerca de 1h30 de estudo: 25 minutos de teoria dirigida e 55 de código avançando o projeto, mais o commit com a tag da aula.

Os compromissos desta série

Código real, nunca pseudocódigo. Todo bloco publicado roda, e o repositório é a prova.

Agnóstico de fornecedor. Tudo funciona com Claude e com GPT, e onde os dois divergem, os dois aparecem lado a lado.

Falhar alto, nunca em silêncio. Sistema de agente que engole erro produz resposta plausível em cima de dado ruim. É a categoria de bug mais cara da área, e a série trata disso como prioridade, não como apêndice.

Medir, não achar. Da Fase 3 em diante, toda escolha de padrão, de modelo e de prompt é defendida com número.

ONDE ACOMPANHAR

As aulas saem no LinkedIn do Prof. Thiago Azeredo Rodrigues, duas por semana durante a temporada. O repositório público, com uma tag por aula, acompanha cada publicação. Salve este PDF: ele é o mapa da série inteira.